

Un Esempio di Applicazione del Filtro di Kalman alle reti WiFi

ilenia.tinnirello@tti.unipa.it

Sommario

- Che cosa e' il filtro di Kalman?

 - [Riepilogo intuitivo]

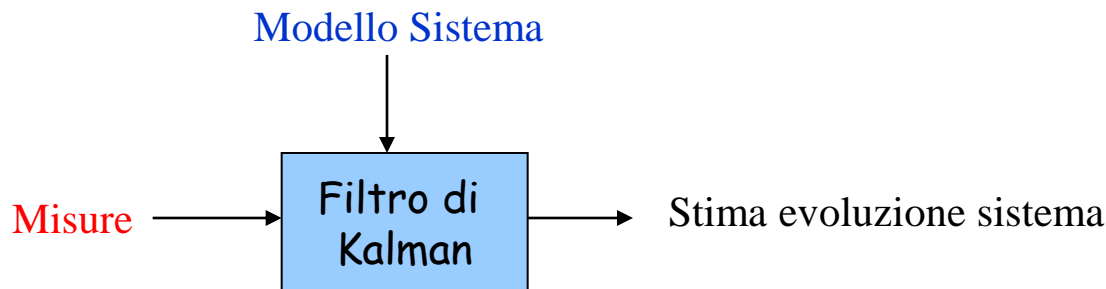

- Come funziona l'accesso al mezzo nelle reti WiFi?

- Come si puo' usare il filtro di Kalman per migliorare le prestazioni delle reti WiFi?

Introduzione al filtro di Kalman

Che cosa e' il filtro di Kalman?

Teoricamente: e' uno strumento per *stimare* lo stato di un sistema dinamico lineare perturbato da rumore, sulla base di misure (o osservazioni) linearmente dipendenti dallo stato e corrotte da rumore. Lo stimatore e' **ottimo** rispetto a qualunque funzione quadratica dell'errore di stima: si basa su tutte le informazioni disponibili.




Che cosa e' il filtro di Kalman?

Praticamente: una delle piu' grandi invenzioni della teoria della stima (e forse del secolo!). Migliaia di applicazioni soprattutto nel campo meccanico e aerospaziale. Non un filtro in senso tradizionale (caratterizzato da poli e zeri), ma piuttosto un "programma". E' ricorsivo: nuove misure possono essere processate via via che arrivano.

Ma e' stimatore o un filtro?

Solitamente il filtro e' un dispositivo che elimina o seleziona alcune componenti frequenziali di segnale -> Si chiama filtro nel senso che elimina il rumore delle misure per costruire le stime.

Stima della posizione di un oggetto fermo



Un osservatore si trova in posizione y ;

Misurando la distanza da un punto di riferimento trova z_1 ; ripetendo la misura ottiene z_2, z_3, z_4 ..

Come si puo' stimare y a partire dalle misure Z ?

Prima misura: $\hat{y} = z_1$;

Seconda misura: $\hat{y} = (z_1 + z_2)/2$; ...

Ogni volta che si dispone di una nuova misura, occorre riutilizzare tutte le precedenti per produrre la nuova stima. Oppure:

$$\hat{y}_{\text{new}} = \hat{y}_{\text{old}} + \alpha(z - \hat{y}_{\text{old}})$$

Dove α puo' essere costante o dipendere dal numero di misure gia' pervenute. Piu' in dettaglio..

Media di misure in modo ricorsivo

$$\hat{y}(1) = z_1; \hat{y}(2) = (z_1 + z_2)/2; \hat{y}(3) = (z_1 + z_2 + z_3)/3; \dots$$

In alternativa:

$$\hat{y}(1) = z_1;$$

$$\hat{y}(2) = (\hat{y}(1) + z_2)/2 = \hat{y}(1) + 1/2 * (z_2 - \hat{y}(1));$$

$$\hat{y}(3) = (\hat{y}(2)*2 + z_3)/3 = \hat{y}(2) + 1/3 * (z_3 - \hat{y}(2));$$

...

$$\hat{y}(n) = (\hat{y}(n-1)*(n-1) + z_n)/n = \hat{y}(n-1) + 1/n * (z_n - \hat{y}(n-1));$$

A partire dalla vecchia stima, ad ogni passo aggiungo un termine pari alla differenza tra nuova misura e vecchia stima. Questo termine (chiamato innovazione) rappresenta l'informazione aggiuntiva rappresentata dalla nuova misura e pesa sempre meno nell'aggiornamento della stima.


Giustificazioni (1)

Le misure Z saranno variabili aleatorie ottenute dalla somma di y e di un rumore v : $Z = y + v$;

Assumiamo v gaussiana a media nulla e varianza σ_v^2 .

Z sara' pure gaussiana a media y e varianza σ_v^2 . Ma non sappiamo quanto vale y ! Posto che y sia noto:


$$f(z/y) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(z-y)^2}{2\sigma^2}\right)$$



Se disponiamo di una sola misura, assumiamo di aver beccato il valore piu' probabile; Poiche' per distribuzione guassiana coincide con il valore medio, assumiamo la stima pari a $z1$. (non e' valido in generale!)

Giustificazioni (2)

E se disponiamo di due misure? Dove sta la vera curva di dispersione delle misure? Quando si ottiene il massimo della pr che su due misure becchiamo giusto i valori $z1$ e $z2$?




Otteniamo il massimo quando il centro della gaussiana (cioe' y) e' collocato a meta' tra $z1$ e $z2$!

Piu' formalmente, dobbiamo annullare la derivata di $f(z1, z2/y)$ rispetto a y .

Con una misura, l'errore dipende da σ_v^2 ; combinando N misure di varianza σ_v^2 , la varianza della stima si riduce a $\sigma_v^2/N \rightarrow$ all'aumentare delle misure disponibili la stima migliora.

Combinazione di misure a diversa precisione




Conviene fare la media? O dobbiamo pesare di piu' la misura piu' accurata? E quanto di piu'?

Si ricava che secondo il criterio di massima verosimiglianza la migliore stima e':

$$\hat{y} = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} z1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} z2$$

Stima della posizione di un oggetto in moto



Un osservatore si trova in posizione y_0 e si muove di moto uniforme con velocità v (che supponiamo nota);

Misurando la distanza da un punto di riferimento trova z_1 ; ripetendo la misura ottiene $z_2, z_3, z_4..$

Supponiamo che una nuova misura sia disponibile ogni T secondi. Come si può stimare $y(t)$ a partire dalle misure Z ? Posso ancora usare le vecchie misure per fare la stima, visto che la posizione cambia?

Stima iniziale:

$$\hat{y}(0) = z_0;$$


Dopo T sec. potro' assumere:

$$\hat{y}(T^-) = z_0 + vT;$$

Appena arriva la nuova misura:

$$\hat{y}(T^+) = (z_0 + vT + z_1)/2 ;$$

Stime per sistemi dinamici (1)




Legge di evoluzione del moto: $y(n) = y_0 + v \cdot nT = y(n-1) + vT$;
Sulla base di questa legge posso aggiornare le stime nel tempo,
anche se non dovessero arrivare altre misure.

$$\hat{y}(0) = z_0; \hat{y}(1) = z_0 + vT; \hat{y}(2) = z_0 + 2vT; \dots$$

N.B. Se v è nota e costante, la stima non degrada con il tempo
(cioè l'errore sulla posizione vera non peggiora):

$$e(0) = y(0) - \hat{y}(0) = y(0) - z_0; e(1) = y(0) + vT - z_0 - vT = e(0); \dots$$

Stime per sistemi dinamici (2)



Legge di evoluzione del moto: $y(n) = y_0 + v(n) \cdot nT$; $v(n) = v + u(n)$;
-> $y(n) = y_0 + v(n) \cdot nT + w$

E se la velocità non è costante, ma ci sono piccole accelerazioni/decelerazioni casuali attorno a v ?

Disponendo della sola misura z_0 , intuitivamente mi aspetto che nel tempo l'incertezza sulla stima peggiori, poiché io non ho modo di rilevare le fluttuazioni di v !

(Se anche z_0 fosse $y(0)$ non posso aspettarmi di continuare a tracciare con esattezza il moto)

Come funziona il filtro di Kalman?

Tiene in considerazione tutto quello che abbiamo detto !
Si basa su un modello di stato così fatto:

$$y(n) = A y(n-1) + w;$$

$$z(n) = H y(n) + v;$$

- 1) Dinamica della grandezza da stimare (legge di aggiornamento dello stato)
- 2) Relazione tra osservazioni (misure) e stato

Algoritmo

Parametri in ingresso: statistiche rumori sullo stato e sulle misure

Supponiamo che al tempo n si dispone della stima $\hat{y}(n)$ con varianza $P(n)$; Al tempo $n+1$:

- 1) **Stima a priori:** prevediamo come si e' evoluto lo stato sulla base della legge del modello
$$\hat{y}(n+1)^- = A \hat{y}(n)^+ ;$$
- 2) **Stima della misura:** prevediamo quale sara' il nuovo valore della misura sulla base del modello
$$\check{z}(n+1) = H \hat{y}(n+1)^-;$$
- 3) **Stima a posteriori:** aggiorniamo la stima con la nuova misura pervenuta (il coefficiente K e' tempo variante e si chiama guadagno di Kalman)
$$\hat{y}(n+1)^+ = \hat{y}(n+1)^- + K (z(n+1) - \check{z}(n+1));$$
- 4) **Aggiorniamo la varianza della stima** tenendo in conto che ogni nuova misura migliora la stima e quindi ne riduce la varianza

MATLAB DEMO

[Estimation of a constant parameter x]

```
function [xhat, P, K] = es_kalman(a, h, sw, sv, x0, xhat0, P0)
```

```
...
```

```
for i=2:1:N
```

```
    x(i)      = a*x(i-1) + sqrt(sw)*randn;
```

```
    z(i)      = h*x(i) + sqrt(sv)*randn;
```

```
    x_a_priori = a*xhat(i-1);
```

```
    z_attesa   = h*x_a_priori;
```

```
    P_a_priori = a^2*P(i-1) + sw;
```

```
    K(i)       = h*P_a_priori/(h^2*P_a_priori + sv);
```

```
    inn(i)     = z(i) - z_attesa;
```

```
    xhat(i)    = x_a_priori + K(i)*inn(i);
```

```
    P(i)       = (1 - h*K(i))*P_a_priori;
```


```
end
```


Meccanismo di accesso al
mezzo in reti WIFI


Basic Service Set (BSS)

group of stations that can communicate with each other

- Infrastructure BSS
 - or, simply, BSS
 - Stations connected through AP




- Independent BSS
 - or IBSS
 - Stations connected in ad-hoc mode



Wireless Ethernet


- 802.3 (Ethernet)
 - CSMA/CD
 - Carrier Sense Multiple Access
 - Collision Detect
- 802.11(wireless LAN)
 - CSMA/CA
 - (Distributed Coordination Function)
 - Carrier Sense Multiple Access
 - Collision Avoidance



- Both A and C sense the channel idle at the same time → they send at the same time.
- Collision can be detected **at sender** in Ethernet.
- Why this is not possible in 802.11?
 1. *Either TX or RX (no simultaneous RX/TX)*
 2. *Large amount of power difference in Tx and Rx (even if simultaneous tx-rx, no possibility in rx while tx-ing)*
 3. *Wireless medium = additional problems vs broadcast cable!!*


Hidden Terminal Problem

- Large difference in signal strength; physical channel impairments (shadowing)
 - It may result that two stations in the same area cannot communicate
- Hidden terminals
 - A and C cannot hear each other
 - A transmits to B
 - C wants to send to B; C cannot receive A; C senses "idle" medium (Carrier Sense fails)
 - Collision occurs at B.
 - A cannot detect the collision (Collision Detection fails).
 - A is "hidden" to C.



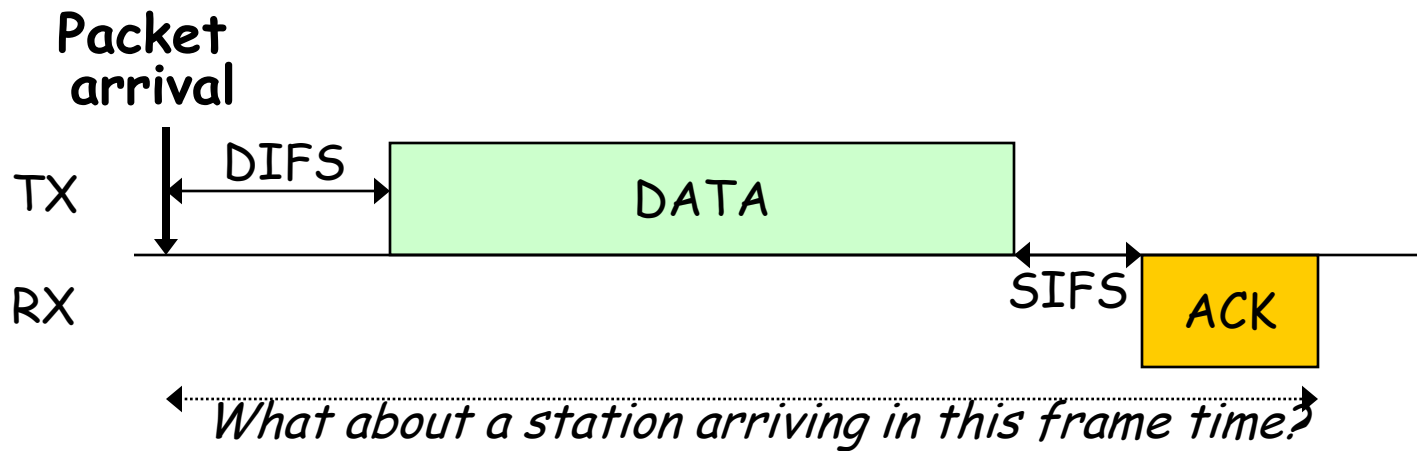
802.11 MAC approach

- Still based on Carrier Sense:
 - Listen before talking
- But collisions can only be inferred afterwards, at the receiver
 - Receivers see corrupted data through a CRC error
 - Transmitters fail to get a response
- Two-way handshaking mechanism to infer collisions
 - DATA-ACK packets



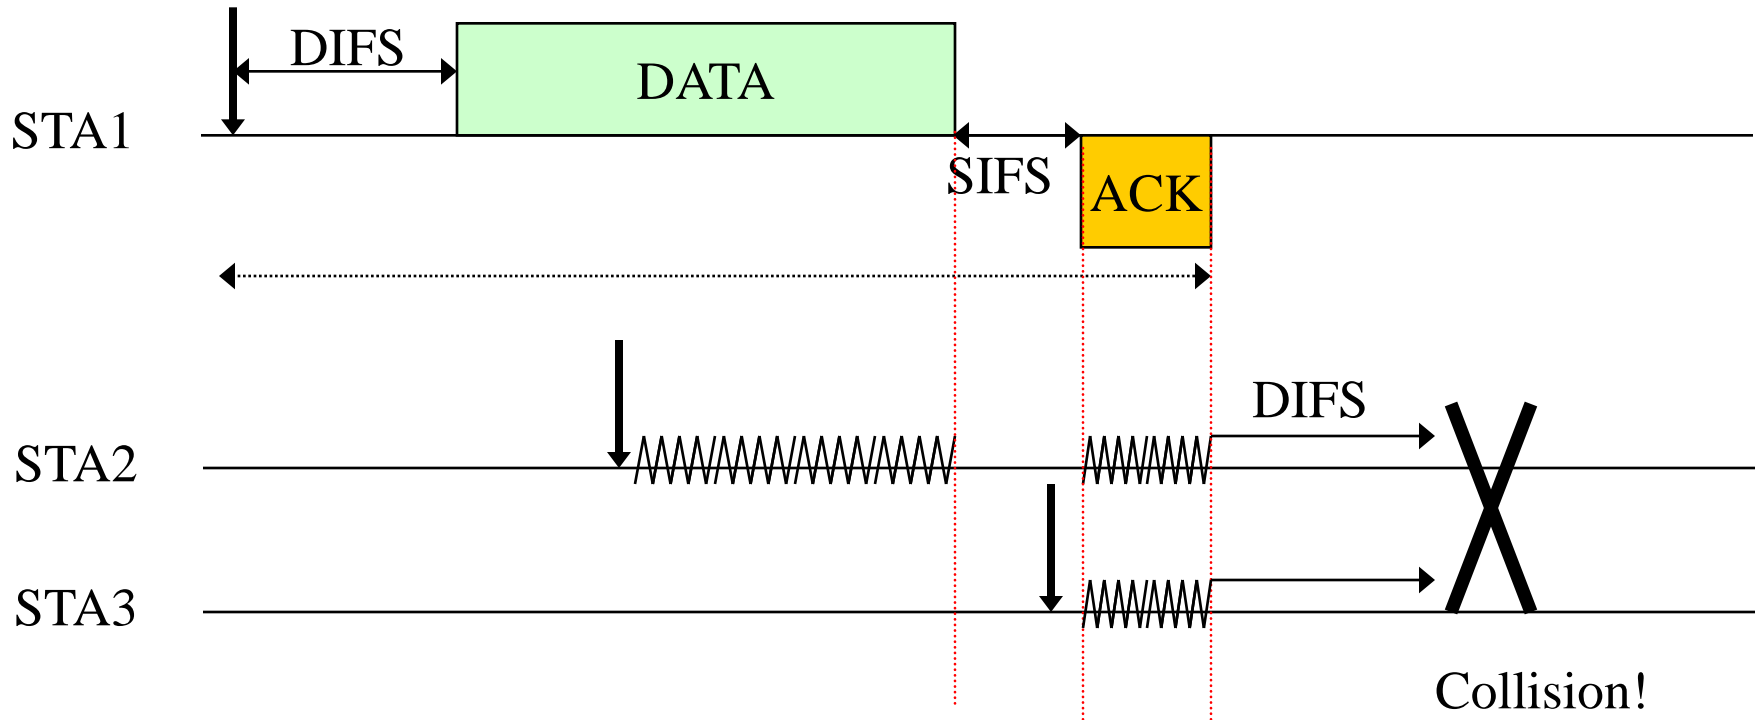
Channel Access details

- A station can transmit only if it senses the channel IDLE for a DIFS time
 - DIFS = Distributed Inter Frame Space



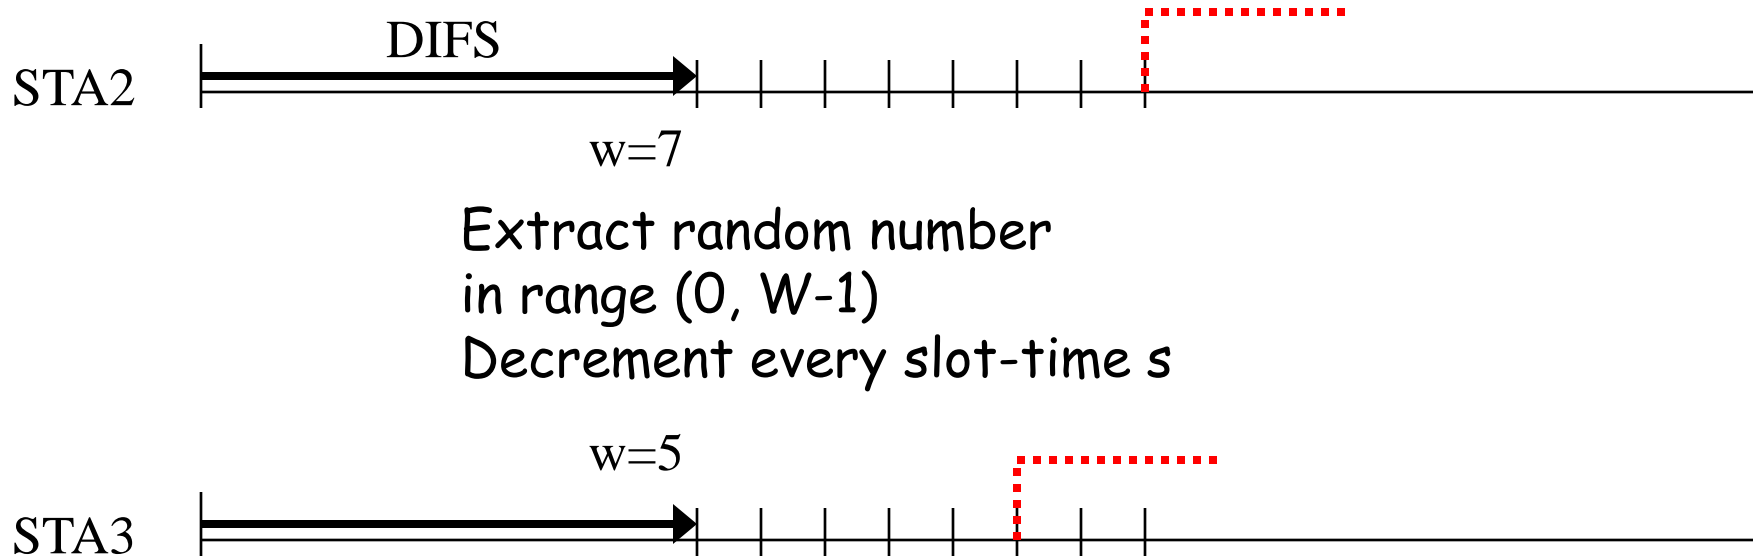
- Key idea: DATA and ACK separated by a different Inter Frame Space
 - ⇒ SIFS = Short Inter Frame Space
 - ⇒ Second station cannot hear a whole DIFS, as $SIFS < DIFS$

Why backoff?



RULE: *when the channel is initially sensed BUSY, station defers transmission;
But when it is sensed IDLE for a DIFS, defer transmission of a further random time
(BACKOFF TIME)*

Slotted Backoff

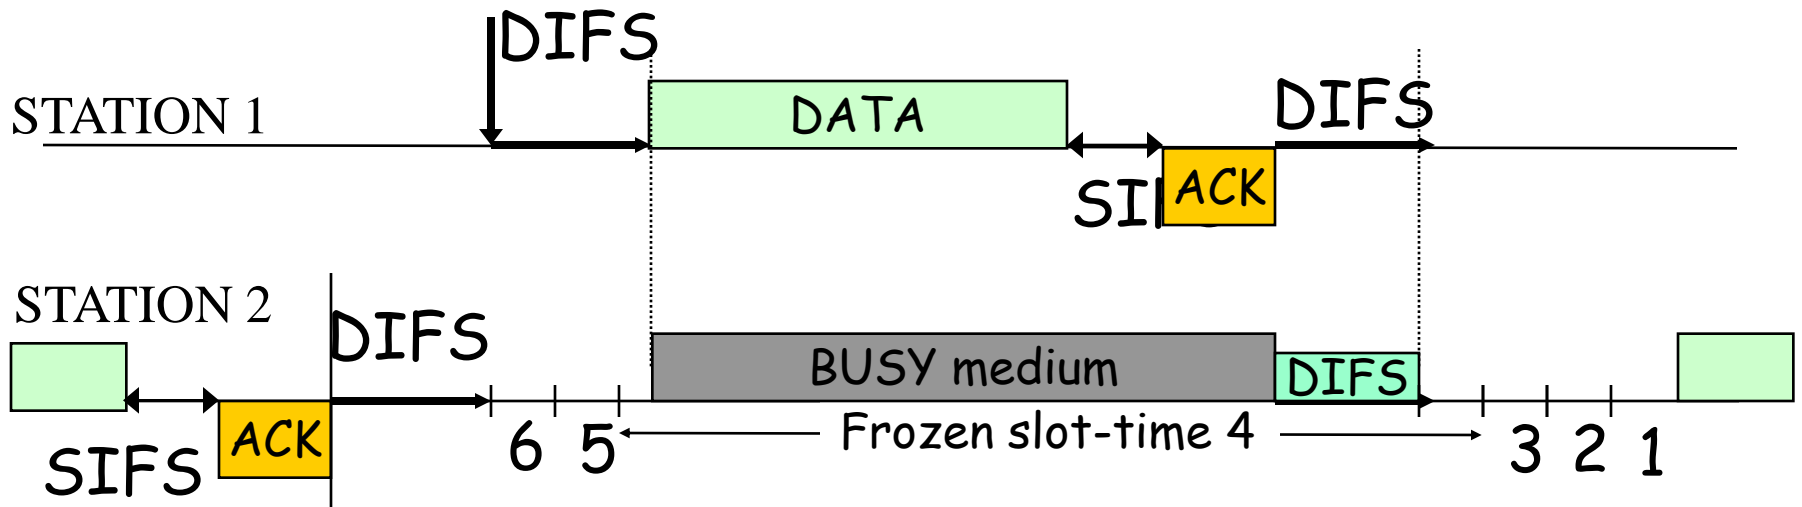


Note: slot times are not physically delimited on the channel!
Rather, they are logically identified by every STA

Slot-time values: 20ms for DSSS (wi-fi)
Accounts for: 1) RX_TX turnaround time
2) busy detect time
3) propagation delay

Backoff freezing

- When STA is in backoff stage:
 - It freezes the backoff counter as long as the channel is sensed BUSY
 - It restarts decrementing the backoff as the channel is sensed IDLE for a DIFS period



Backoff rules


- First backoff value:
 - Extract a uniform random number in range $(0, CW_{\min})$
- If unsuccessful TX:
 - Extract a uniform random number in range $(0, 2 \times (CW_{\min} + 1) - 1)$
- If unsuccessful TX:
 - Extract a uniform random number in range $(0, 2^2 \times (CW_{\min} + 1) - 1)$
- Etc up to $2^m \times (CW_{\min} + 1) - 1$

Exponential Backoff!

$CW_{\min} = 31$

$CW_{\max} = 1023$ ($m=5$)

Throughput vs CW_{min}




CW_{opt} depends on n !!

Stima del numero di
stazioni in reti WiFi

Who knows n in DCF?

In Distributed Systems:

- Lack of direct knowledge of traffic load
 - Even AP is not able to provide such an information:
of "associated" stations can be very different from the # of active stations
- **Possible indirect estimation** of traffic load via run-time monitoring of channel status



Theoretical finding

Assumption: active stations have always queues not empty

Based on previously developed time-discrete Markov model for CSMA/CA:

$$n = 1 + \frac{\text{Log}(1 - p)}{\text{Log}\left(1 + \frac{2(1 - 2p)}{p(w + 2) + pw(2p)^m - (w + 1)}\right)}$$


n = number of active users

p = collision probability seen by a competing MS

w = min. contention window (32 for FHSS, 16 for DSSS)

m = backoff stages (5 for FHSS, 6 for DSSS)

Analysis vs. Simulation (accurate model < 3%)




$n = f(p)$: Strongly not linear relation!

Key idea: monitoring the channel all the time!


..instead of considering only our `ACK_TIMEOUTS`.

- Direct **pc** measurement: by looking at all the slots in which the target station (e.g. station red) does not transmit

- 1) Busy slots = potential collisions
- 2) Idle slots = potential success



$$pc = C_{busy} / B$$




Run-Time Measurements

If stations activate/deactivate dynamically, congestion levels and interference conditions are time-varying.

Each station can perform its pc and pr measurements at different time-windows

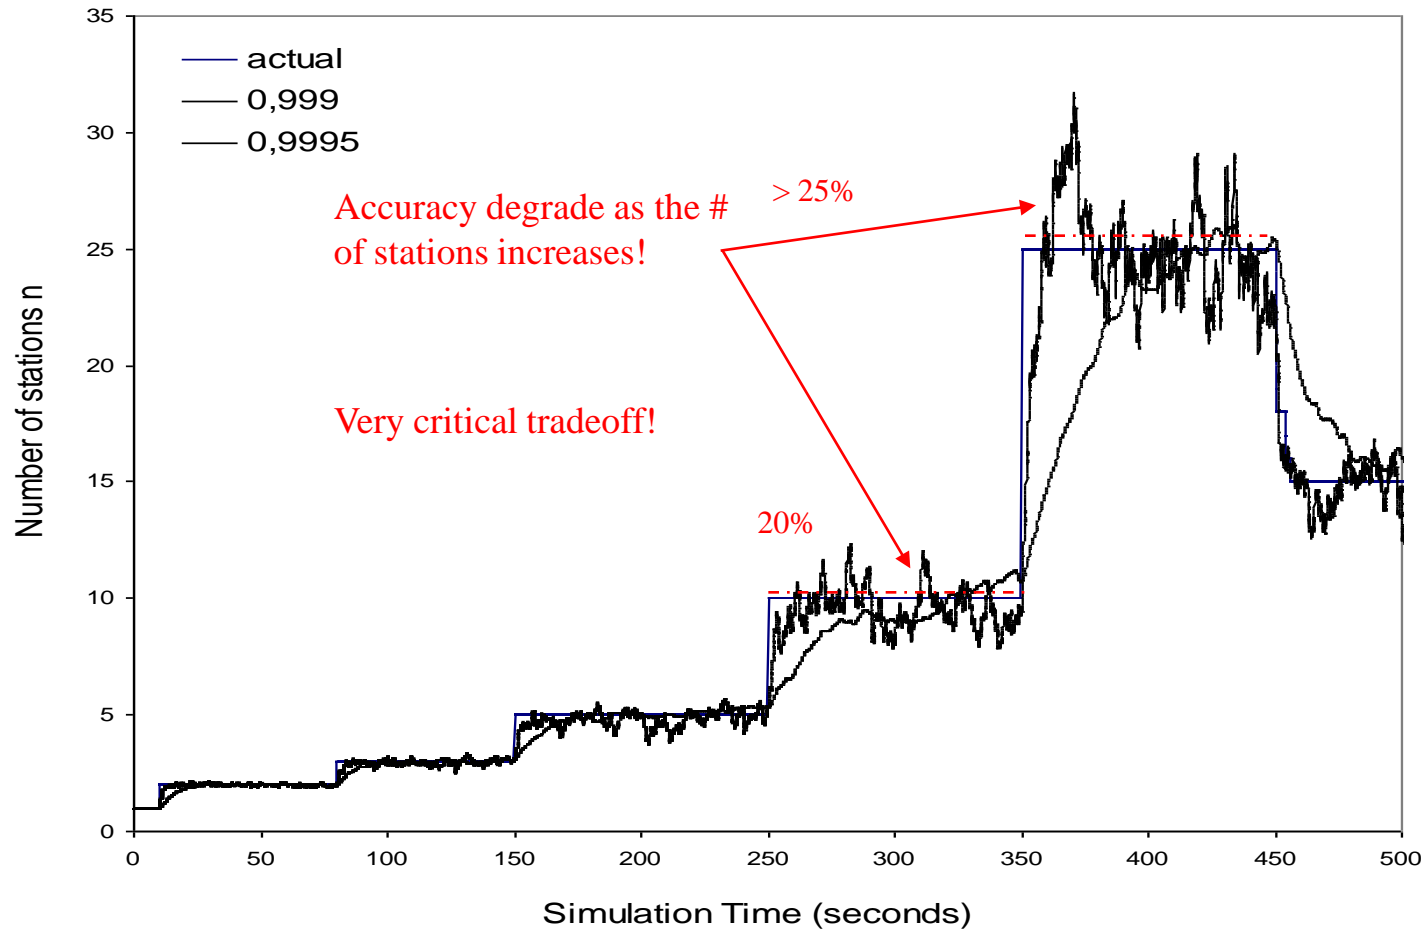
Measurement smoothing obtained by filtering



ARMA filters: usual accuracy/tracking tradeoff..

$$\begin{cases} \hat{p}(t+1) = \alpha \hat{p}(t) + \frac{(1-\alpha)}{q} \sum_{i=0}^{q-1} C_{t-i} \\ \hat{n}(t+1) = f(\hat{p}(t+1)) \end{cases}$$

ARMA Filtering



Kalman Filtering

- Allows to obtain fast tracking in the transient phase and error minimizing in stationary conditions
 - It works as an AR filter with time-varying α coefficient
- Include available information (e.g. measurement statistics, non linearity) in the filtering process
- Model not available information (e.g. MS activation/deactivation) as a noise

$$n_k = n_{k-1} + w_k$$

$$p_k = f^1(n_k) + v_k$$

Model

Kalman Filter Design (1)

Not coefficient settings, but model definition

- a) system state = number of competing stations
- b) observable parameter (measure) = collision probability
- c) relation between state and measure = $f()$ or $f^{-1}()$
- d) measure variance $R_k = ?$
- e) state dynamic = state noise variance $Q_k = ?$

$$\begin{cases} n_k = n_{k-1} + w_k \\ p_k = f^{-1}(n_k) + v_k \end{cases}$$

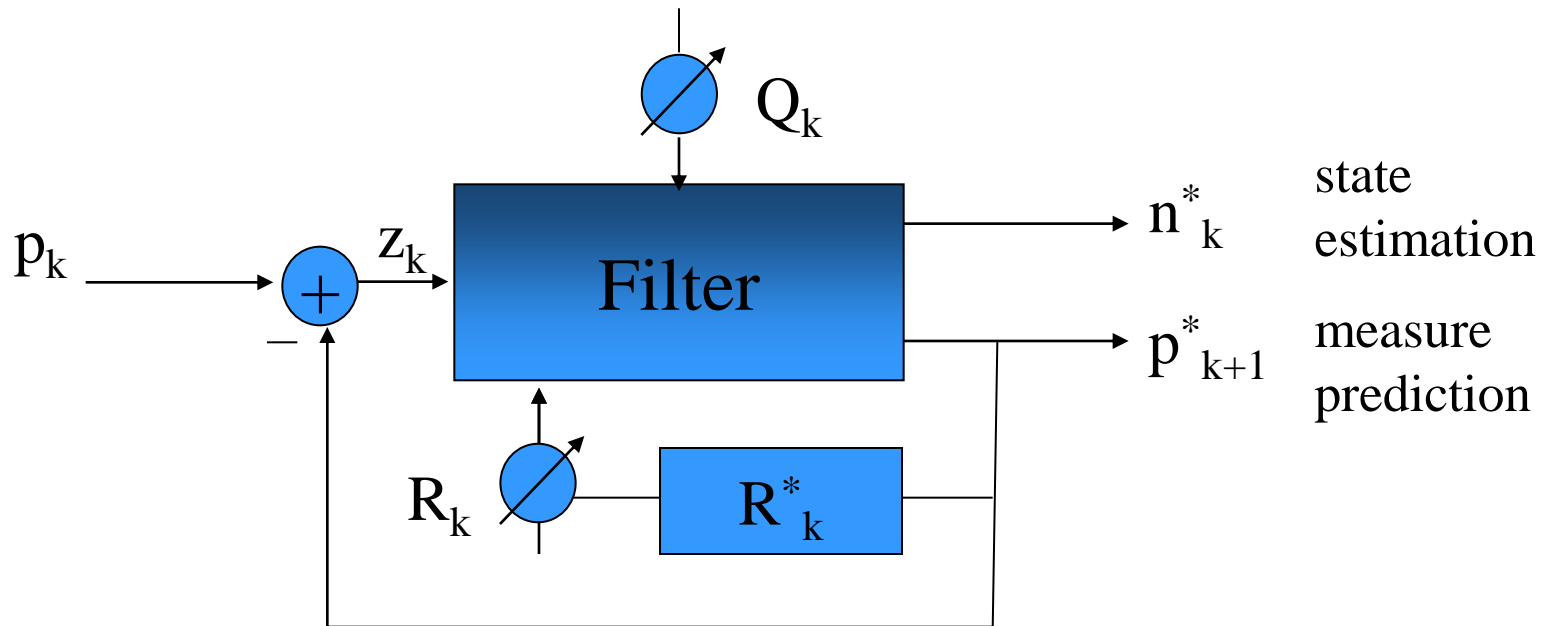
Kalman Filter Design (2)

From model to filter:


$$z_k = p_k - p_k^* \quad n_k = n_{k-1} + K_k z_k \quad p_{k+1}^* = f^1(n_k^*)$$

Two design parameters: Q_k , R_k

Measure statistics can be estimated!



What value for Q_k ?



Again accuracy/tracking tradeoff problem!

What new with respect to ARMA filter?

MATLAB DEMO

[Estimation of a parameter x with step-wise dynamics]

```
function [xhat, P, K] = es_kalman(a, h, sw, sv, x0, xhat0, P0)
```

```
...
```

```
for i=2:1:N
```

```
    x(i)      = a*x(i-1) + u(i) + sqrt(sw)*randn;
```

```
    z(i)      = h*x(i) + sqrt(sv)*randn;
```

```
    x_a_priori = a*xhat(i-1);
```

```
    z_attesa   = h*x_a_priori;
```

```
    P_a_priori = a^2*P(i-1) + sw;
```

```
    K(i)       = h*P_a_priori/(h^2*P_a_priori + sv);
```

```
    inn(i)     = z(i) - z_attesa;
```

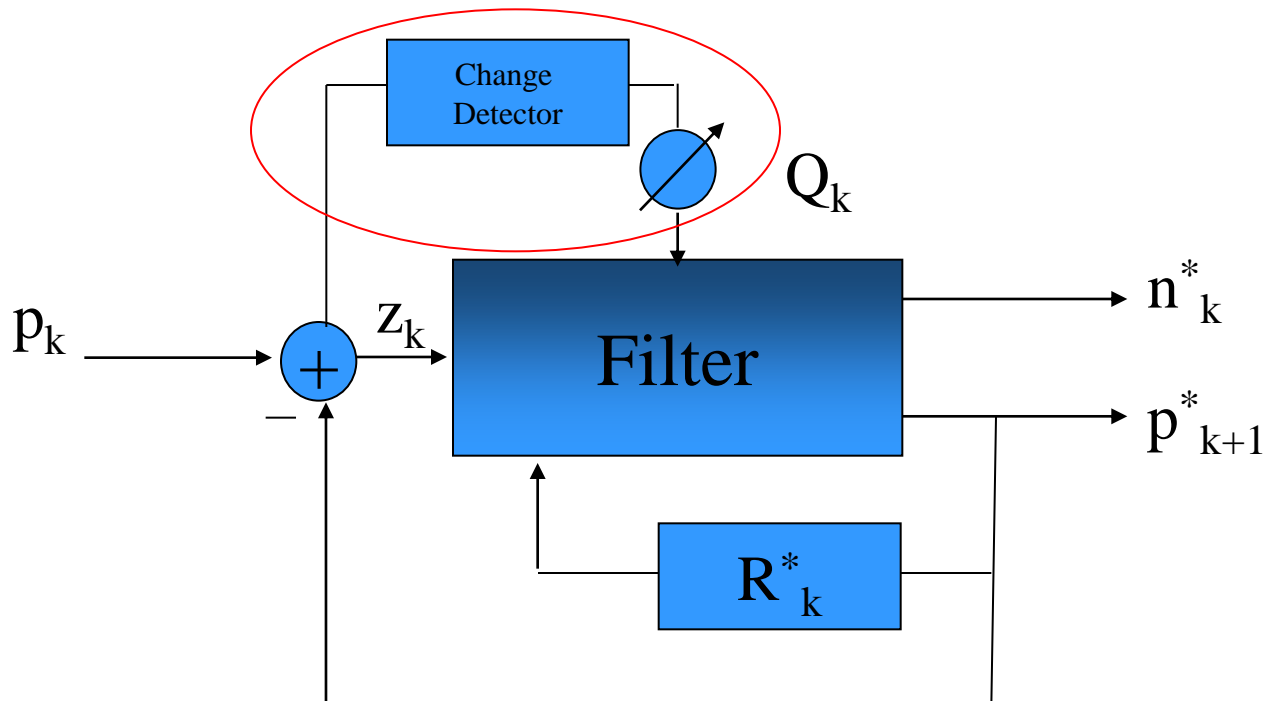
```
    xhat(i)    = x_a_priori + K(i)*inn(i);
```

```
    P(i)       = (1 - h*K(i))*P_a_priori;
```

```
end
```



Automatic Q_k setting

- Further filter (change detector) for Q_k driving based on innovations
 - Innovations process is a white process with zero mean in stationary conditions: the filtering can allow to distinguish between transient and stationary phases

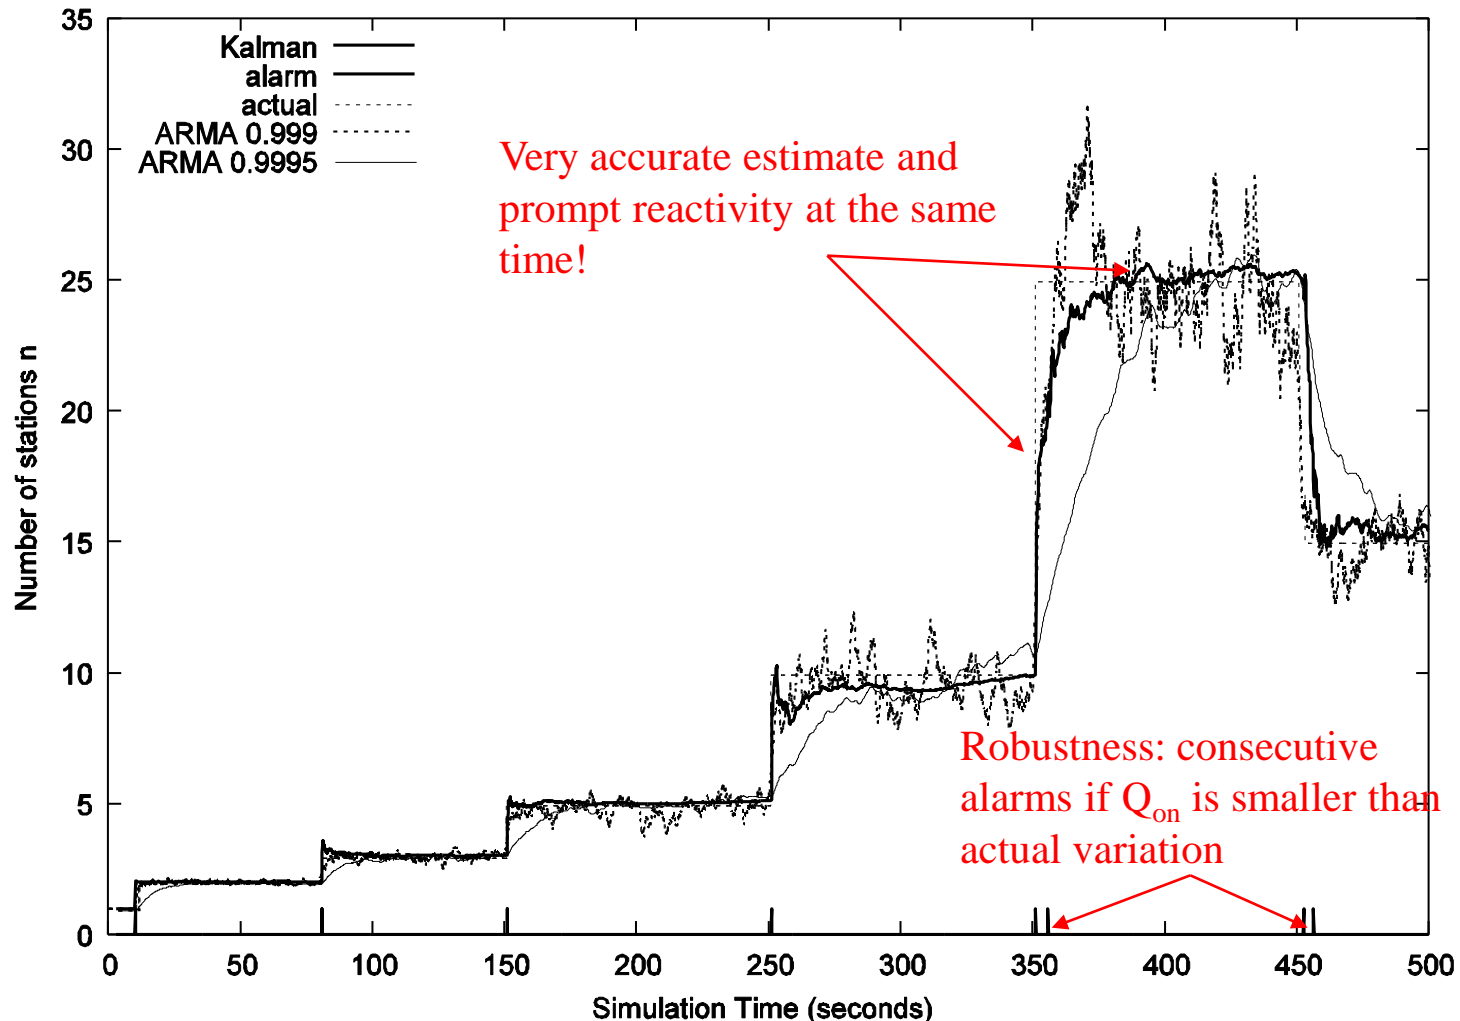


CUSUM Test for Q_k switching

- Basically: cumulative sum of innovations; alarm when such a sum overcomes a given threshold.



Performance Evaluation



MATLAB DEMO

*[Estimation of a parameter x with step-wise dynamics;
CUSUM test on innovation process]*

```
function [xhat, P, K] = es_kalman(a, h, sw, sv, x0, xhat0, P0)
```

```
...
```

```
for i=2:1:N
```

```
    x(i)      = a*x(i-1) + u(i) + sqrt(sw)*randn;
```

```
    z(i)      = h*x(i) + sqrt(sv)*randn;
```

```
    x_a_priori = a*xhat(i-1);
```

```
    z_attesa   = h*x_a_priori;
```

```
    P_a_priori = a^2*P(i-1) + sw;
```

```
...
```

```
    cusum1(i) = max (cusum1(i)+inn(i)-0.5, 0);
```

```
    cusum2(i) = min (cusum2(i)-+nn(i)+0.5, 0);
```

```
end
```